RESUMEN

¿Quién tendrá dificultades de pago el próximo mes? Tres modelos interpretables

Árbol de decisión, regresión logística y EBM sobre 25.000 clientes · toda decisión tomada con validación cruzada estratificada de 5 folds

25.000
clientes de entrenamiento · 15 variables (historial de pago 6 meses, facturas, demografía, plan de asistencia)

21,2 %
tienen dificultad de pago → baseline de accuracy 0,788 y foco en balanced accuracy / recall

0,776
ROC AUC del EBM, el mejor modelo en todas las métricas → usado para **test.csv**

0,30 → 0,58
recall del EBM al bajar el umbral de 0,5 a 0,25 (balanced acc. 0,63 → 0,70)

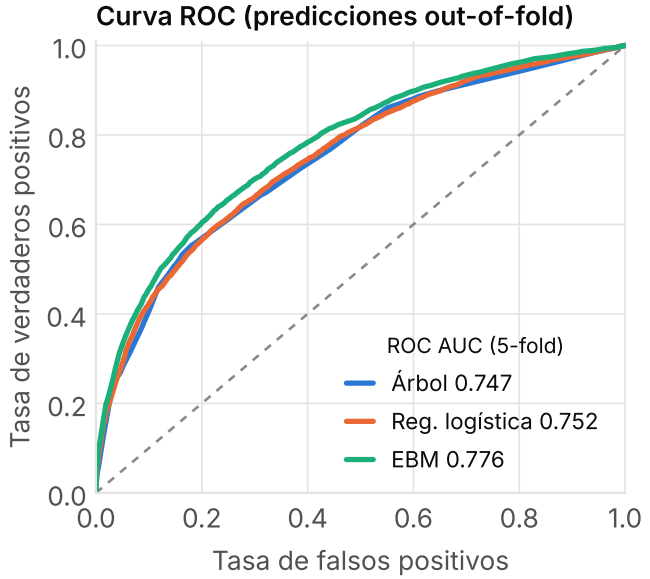
RESULTADOS · 5-FOLD CV (MEDIA ± DESV.)

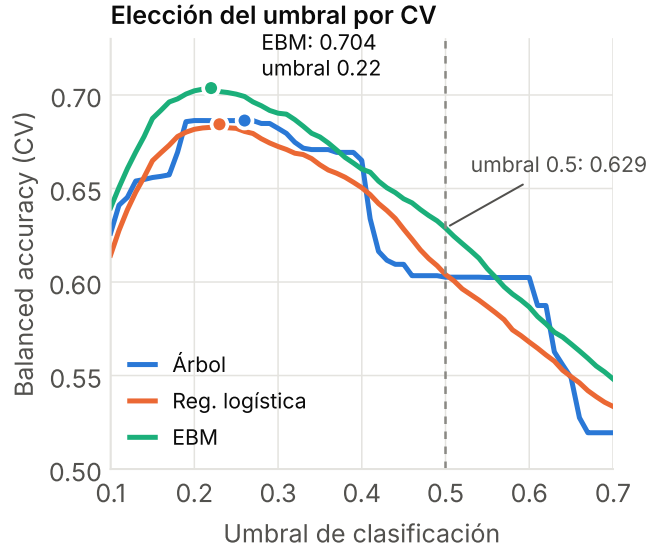
Clasificador	Ajustes clave	Acc.	Bal. acc.	Recall	ROC AUC
DecisionTree	entropy, depth 4, min_leaf 100	0,813	0,603	0,237	0,747 ±0,005
LogisticRegression	L2, C = 0,1, estandarizado	0,811	0,604	0,245	0,752 ±0,006
EBM	**interactions = 0**	**0,819**	**0,629**	**0,299**	**0,776 ±0,005**

Umbral 0,5 · hiperparámetros por GridSearchCV (ROC AUC) · one-hot en categóricas, escalado solo en la RL

LO QUE HEMOS APRENDIDO

- Los tres modelos coinciden: **el comportamiento de pago reciente domina** (estado del último pago, meses sin pagar, ratio pago/factura). La demografía apenas pesa.
- El EBM gana +0,03 de AUC **sin perder interpretabilidad**: capta efectos no lineales (edad, ratio pago/factura) que la RL fuerza a ser rectas.
- Las explicaciones **discrepan** en los casos B y C (casi idénticos): el árbol ignora el plan de asistencia, la RL y el EBM no.





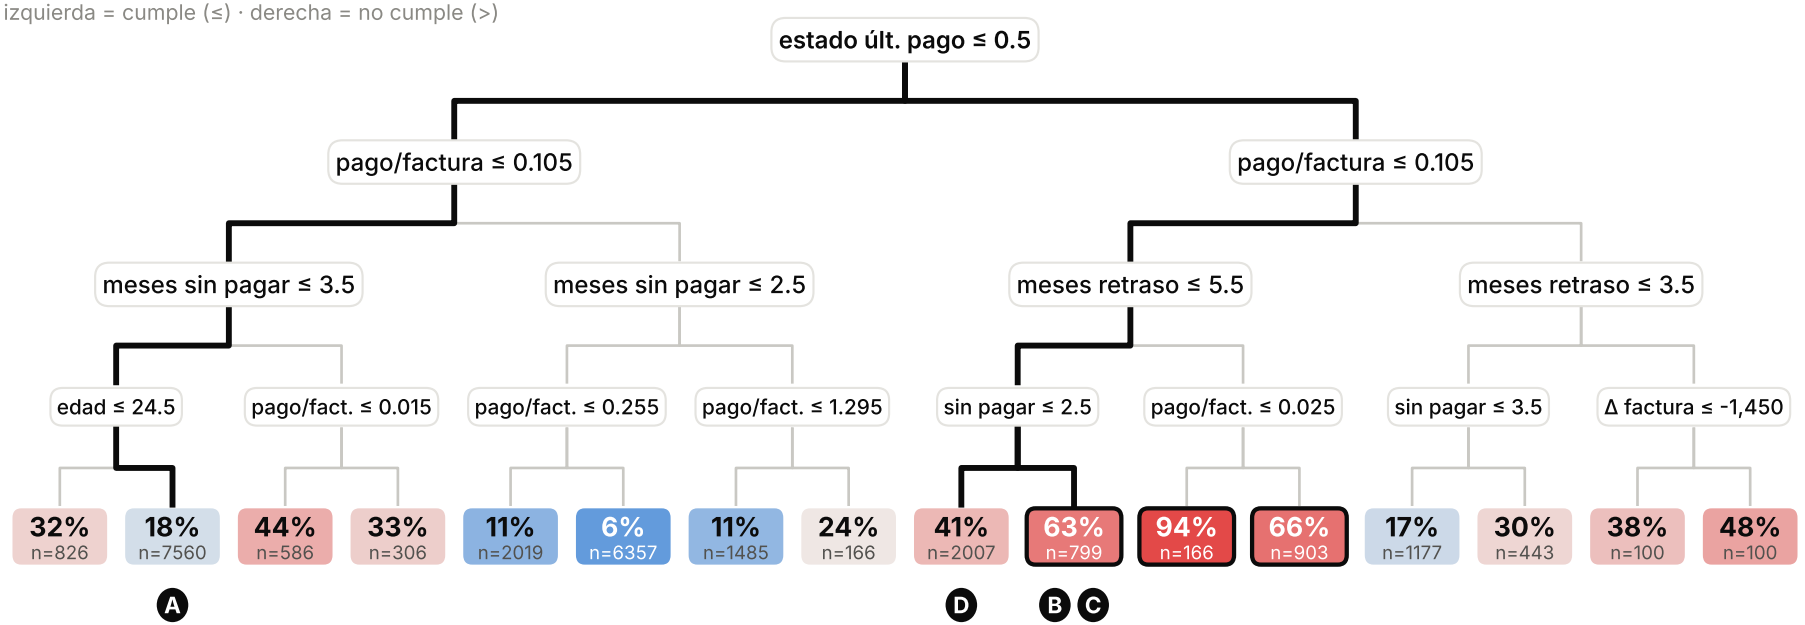
test.csv con umbral 0,5: casi el óptimo de accuracy (0,46), la métrica con que se evalúa; el umbral bajo es preferible si importa detectar impagos.

MODELO LÓGICO

Árbol de decisión: 16 hojas que, en el fondo, son una sola regla

CART, criterio entropía, profundidad 4, ≥ 100 clientes por hoja · color = % con dificultad en la hoja (gris = tasa base 21 %) · caminos de los casos A–D en negro

izquierda = cumple (≤) · derecha = no cumple (>)



INTERPRETACIÓN GLOBAL

Solo 3 de 16 hojas predicen la clase 1 con umbral 0,5. Juntas equivalen a **una regla**:

> SI **estado último pago ≥ 1** Y **pago/factura ≤ 0,10** Y (**meses sin pagar ≥ 3** O **6 meses con retraso**) → **dificultad**

Cubre 1.868 clientes con 67 % de precisión. El resto de divisiones solo afinan probabilidades (útiles para el ROC y para bajar el umbral) → podría podarse a una lista de reglas.

¿QUÉ USA EL ÁRBOL?

Importancia (reducción de entropía):

- estado último pago **50 %**
- ratio pago/factura **33 %**
- meses sin pagar **9 %** · meses con retraso **5 %**
- edad **2 %** (corte en 24,5 años)

Sexo, educación, estado civil y plan de asistencia: **0**.

INTERPRETACIÓN LOCAL · MISMOS CASOS EN LOS 3 MODELOS

A **real 0**, al día, paga el 7 %: hoja 18 % → **0** ✓

B **real 0** y **C** **real 1**: 6 meses sin pagar, mismo historial. Caen en la **misma hoja (63 %)** → ambos 1.

D **real 1**, 2 meses de retraso, utilización 99 %, pero paga todos los meses: hoja 41 % → **0** × (con umbral 0,25 sí acierta)

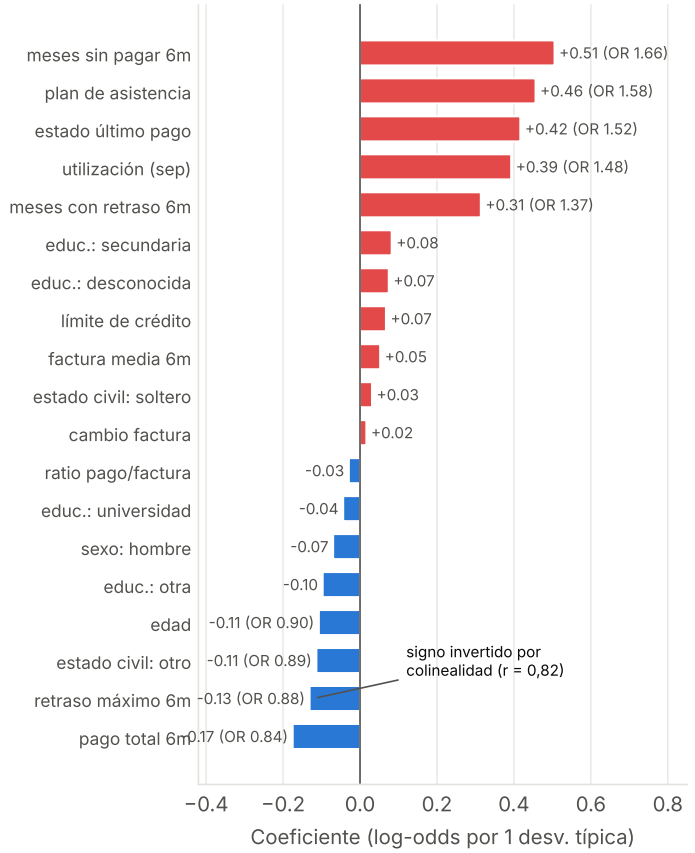
B y C solo difieren en plan de asistencia, edad, sexo y límite: **el árbol no puede separarlos**. B es un falso positivo inevitable.

MODELO LINEAL

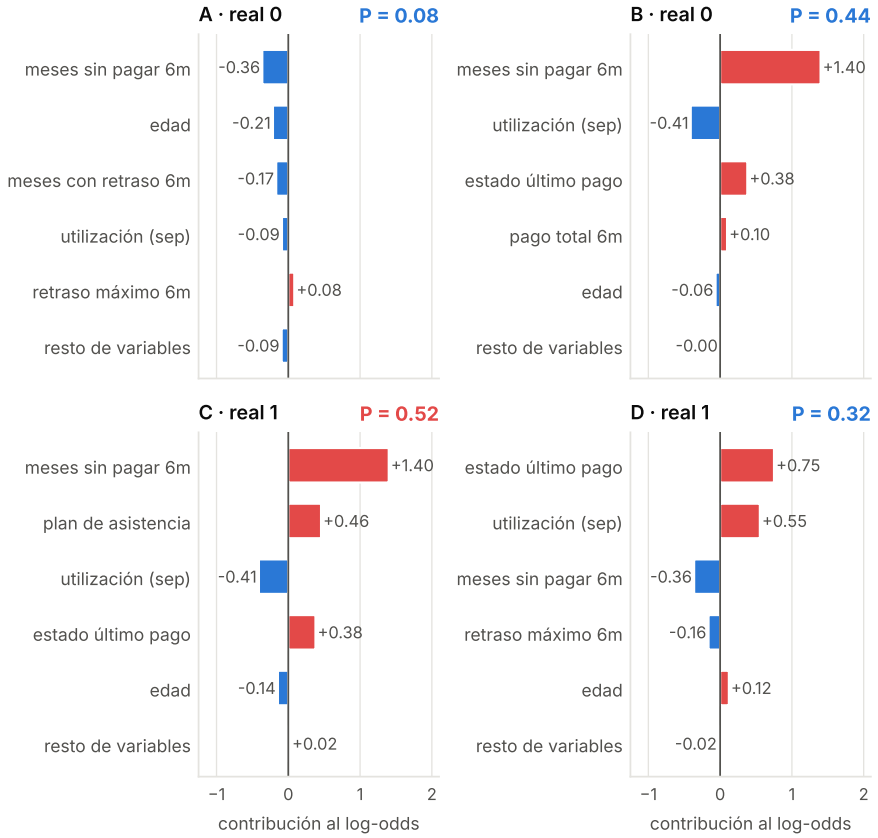
Regresión logística: efectos aditivos y comparables, leídos con cuidado

L2 con C = 0,1 elegido por CV (ROC AUC 0,752) · variables numéricas estandarizadas → cada coeficiente es el cambio en log-odds por una desviación típica

INTERPRETACIÓN GLOBAL · COEFICIENTES



LOCAL · CONTRIBUCIÓN = COEF × VALOR ESTANDARIZADO



GLOBAL

- Riesgo: **meses sin pagar** (OR 1,66), **plan de asistencia** (OR 1,58), **estado último pago** y **utilización**.
- Protectores: **pago total** y **edad**.
- **retraso máximo** sale negativo: correlación 0,82 con meses con retraso. Es reparto de peso entre variables colineales, no un efecto real.

EL CASO MÁS INTERESANTE: B FRENTE A C

Comparten los mismos +1,40 por 6 meses sin pagar. El **plan de asistencia (+0,46)** lleva a C por encima de 0,5:

B = 0,44 → 0 ✓ C = 0,52 → 1 ✓

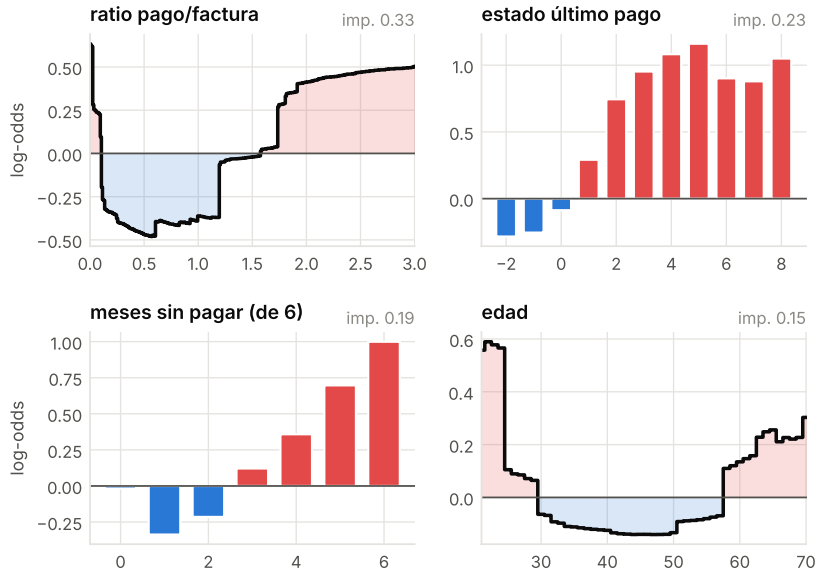
La RL acierta donde el árbol fallaba. Ojo: el plan es una **señal** de dificultad previa, no su causa.

MODELO ADITIVO

EBM: el mejor modelo, con formas no lineales que la RL no puede ver

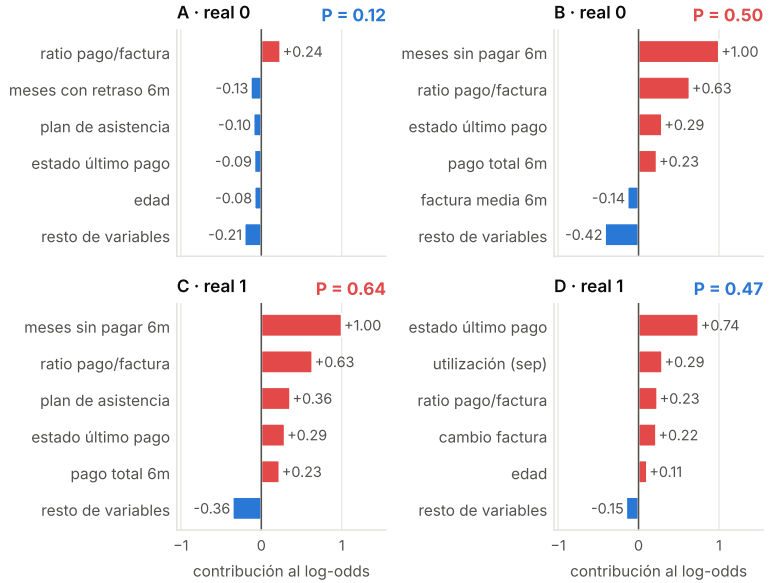
ExplainableBoostingClassifier, interactions = 0 · ROC AUC 0,776 · una función de forma $f_j(x_j)$ por variable · **rojo = sube el riesgo**, **azul = lo baja**

INTERPRETACIÓN GLOBAL · FUNCIONES DE FORMA



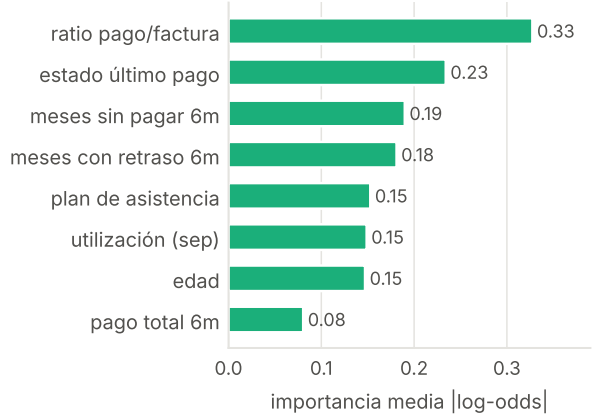
- **Pago/factura**: riesgo máximo si no se paga; cae en 0,10 (**el mismo corte que el árbol**) y vuelve a ser de riesgo por encima de 1,7 (pagar mucho más que la factura).
- **Edad**: forma en U, salto en 24,5 años (otra vez el corte del árbol). La RL solo ve una recta.

INTERPRETACIÓN LOCAL · CONTRIBUCIONES DEL EBM

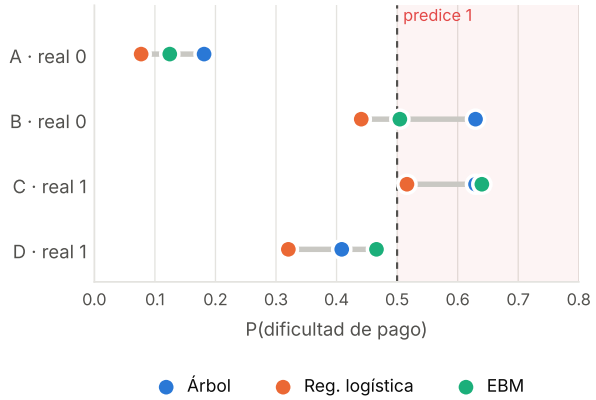


C supera a B por el plan de asistencia (+0,36 frente a −0,10). D obtiene la probabilidad más alta de los tres modelos gracias a estado de pago 2 (+0,74) y utilización 99 % (+0,29).

IMPORTANCIA GLOBAL



LOS 3 MODELOS, MISMOS CASOS



Coinciden en A; discrepan en B (justo en el umbral). Ninguno detecta D con 0,5; los tres con 0,25.