RESUMEN

¿Quién tendrá dificultades de pago el próximo mes? Tres modelos interpretables

Árbol de decisión, regresión logística y EBM sobre 25.000 clientes · toda decisión tomada con validación cruzada estratificada de 5 folds

25.000
clientes de entrenamiento · 15 variables (historial de pago 6 meses, facturas, demografía, plan de asistencia)

21,2 %
tienen dificultad de pago → baseline de accuracy 0,788 y foco en balanced accuracy / recall

0,776
ROC AUC del EBM, el mejor en todas las métricas salvo precision → usado para **test.csv**

0,30 → 0,58
recall del EBM al bajar el umbral de 0,5 a 0,25 (balanced acc. 0,629 → 0,700; accuracy 0,819 → 0,768)

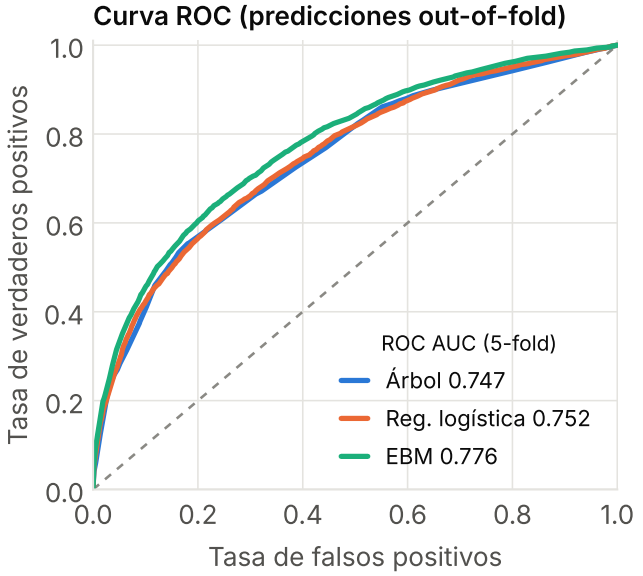
RESULTADOS · 5-FOLD CV (MEDIA ± DESV.)

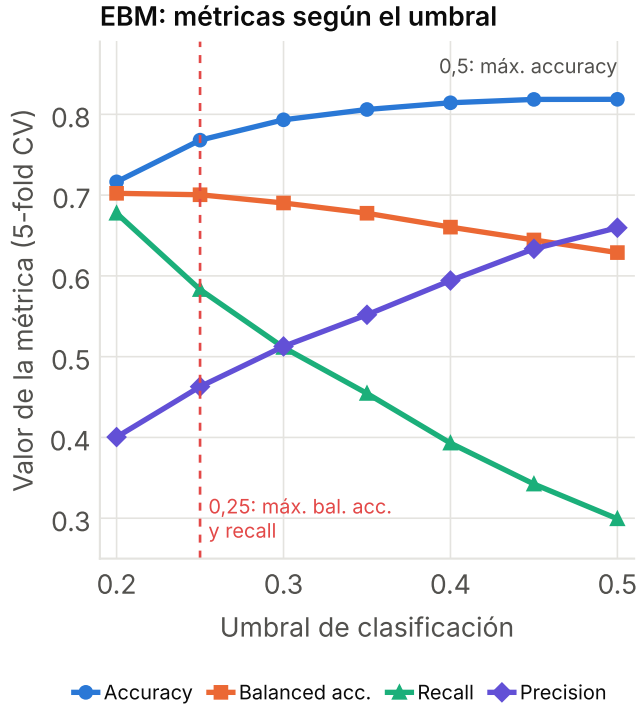
Clasificador	Ajustes clave	Acc.	Bal. acc.	Recall	F1	ROC AUC
DecisionTree	entropy, depth 4, min_leaf 100	0,813	0,603	0,237	0,350	0,747 ±0,005
LogisticRegression	L2, C = 0,1	0,811	0,604	0,245	0,354	0,752 ±0,006
EBM	**interactions = 0**	**0,819**	**0,629**	**0,299**	**0,412**	**0,776 ±0,005**

Umbral 0,5 · hiperparámetros por GridSearchCV (ROC AUC) · one-hot en categóricas, escalado solo en la RL

LO QUE HEMOS APRENDIDO

- Los tres modelos coinciden: **el comportamiento de pago reciente domina** (estado del último pago, meses sin pagar, pago/factura); la demografía apenas pesa.
- El EBM gana +0,03 de AUC **sin perder interpretabilidad**: capta formas en U (edad, pago/factura) que la RL reduce a rectas.
- Limitación común: en cuentas casi inactivas ninguna variable distingue **"no paga lo que debe"** de **"no debe nada"** → el árbol confunde FP y TP; la RL solo los separa por el plan de asistencia.





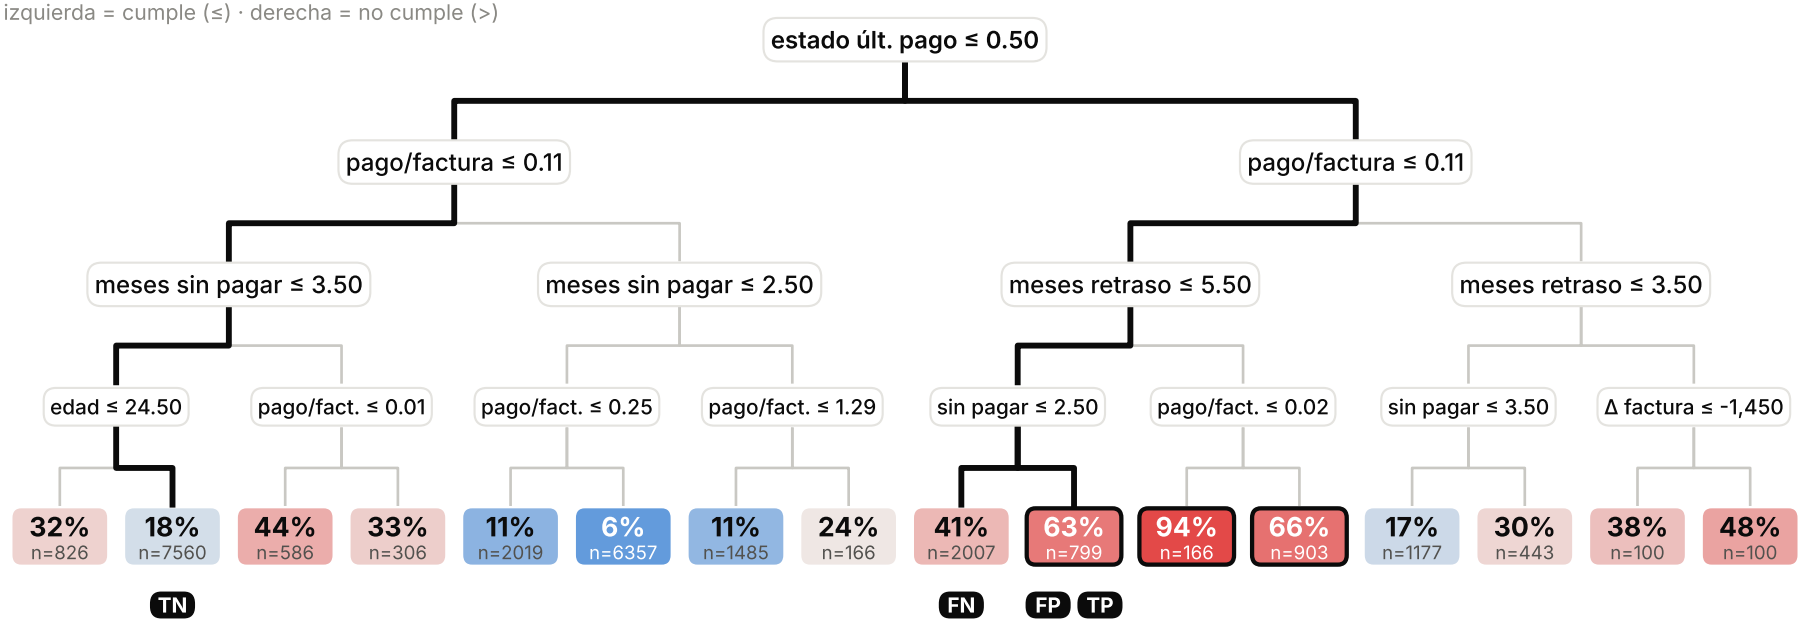
Umbrales de 0,20 a 0,50 sobre predicciones out-of-fold. test.csv: EBM con umbral 0,5 (mayor accuracy, la métrica de evaluación); en un banco real, 0,25.

MODELO LÓGICO

Árbol de decisión: 16 hojas que, en el fondo, son una sola regla

Entropía, profundidad 4, ≥ 100 clientes por hoja · color = % con dificultad en la hoja (gris = tasa base 21 %) · en negro, los 4 casos locales

izquierda = cumple (≤) · derecha = no cumple (>)



INTERPRETACIÓN GLOBAL

Solo 3 de 16 hojas predicen la clase 1 con umbral 0,5. Juntas equivalen a **una regla**:

> SI **estado último pago ≥ 1** Y **pago/factura ≤ 0,11** Y (**meses sin pagar ≥ 3** O **6 meses con retraso**) → **dificultad**

Cubre 1.868 clientes con 67 % de precisión. Las 8 hojas de la rama izquierda predicen 0: con las mismas predicciones cabe una lista de reglas mucho más corta (GOSDT / imodels).

¿QUÉ USA EL ÁRBOL?

Importancia (reducción de entropía):

- estado último pago **50 %**
- ratio pago/factura **33 %**
- meses sin pagar **9 %** · meses con retraso **5 %**
- edad **2 %** (corte en 24,5 años)

Sexo, educación y estado civil: **0**. También deja fuera la utilización y el plan de asistencia.

INTERPRETACIÓN LOCAL · MISMOS CASOS EN LOS 3 MODELOS

TN estado de pago 0 (sin retraso), paga todos los meses, 54 años: hoja más poblada (7.560), P = 0,181 → **0** ✓

FP **TP** mismo recorrido y **misma hoja (P = 0,630)**: 1 mes de retraso, ratio 0 y 6 meses sin abonos.

FN 2 meses de retraso pero paga todos los meses: hoja P = 0,409 → **0** ×. Ignora utilización 99 %; con t = 0,25 acertaría.

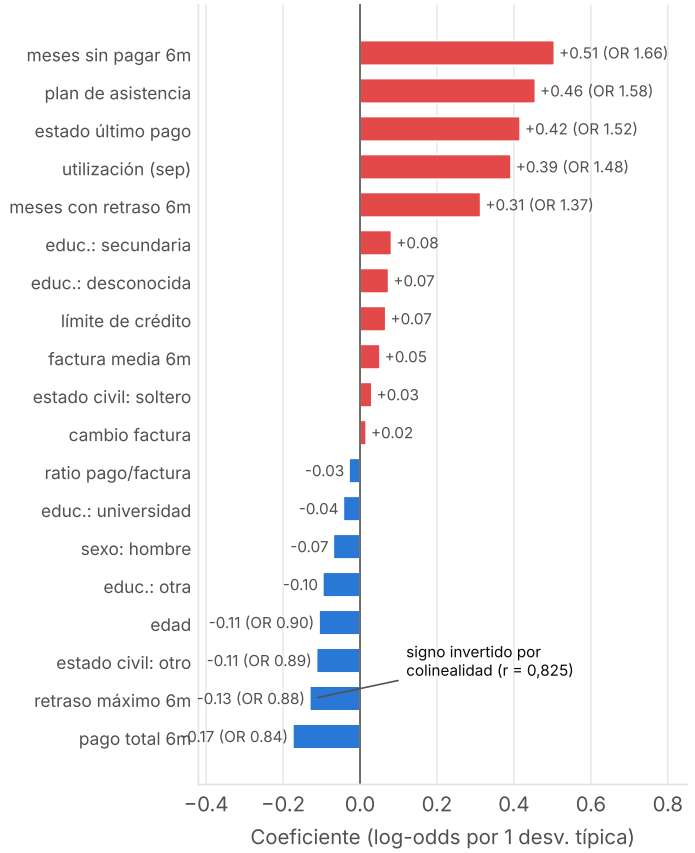
Pero su factura media es ≈ 0: cuentas inactivas, **"no debe nada"**, no "no paga". El árbol no puede separarlos; el 37 % de esa hoja no tiene dificultades.

MODELO LINEAL

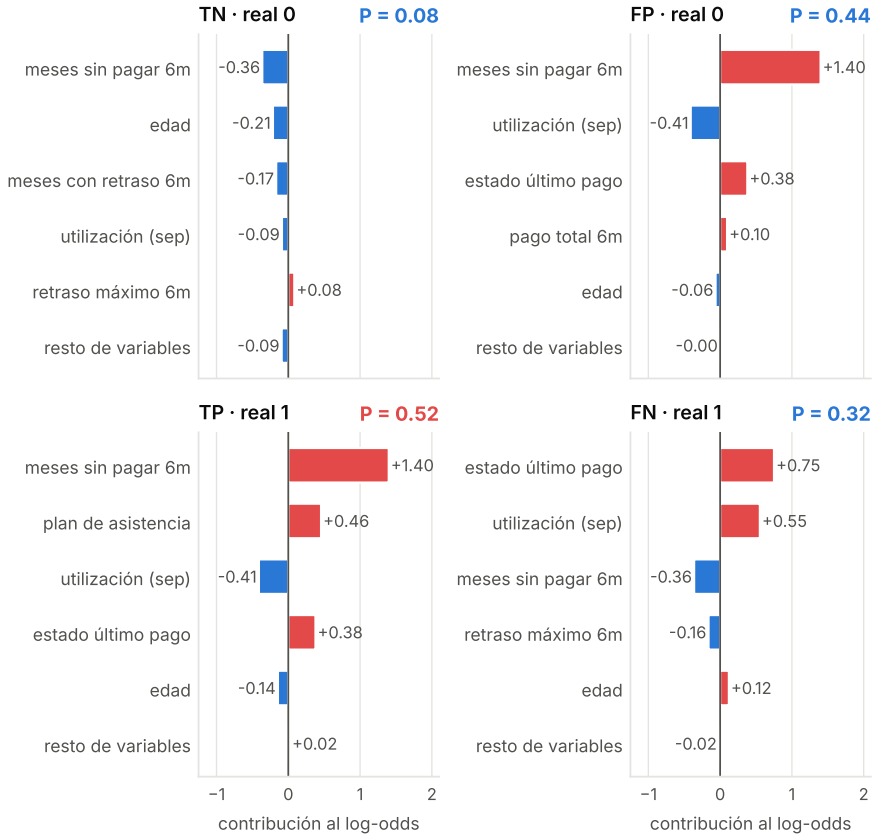
Regresión logística: efectos aditivos y comparables, leídos con cuidado

L2 con C = 0,1 elegido por CV (ROC AUC 0,752) · numéricas estandarizadas → cada β es el cambio en log-odds por 1 desv. típica · β_0 = −1,64 (P base 16,3 %)

INTERPRETACIÓN GLOBAL · COEFICIENTES



LOCAL · CONTRIBUCIÓN = COEF × VALOR ESTANDARIZADO



GLOBAL

- Riesgo: **meses sin pagar** (OR 1,66), **plan de asistencia** (OR 1,58), **estado último pago** y **utilización**.
- Protectores: **pago total** y **edad**.
- **retraso máximo** sale negativo por colinealidad con meses con retraso (r = 0,825): con los meses fijos, un pico pasado ya regularizado indica capacidad de subsanar.

RESUELVE LA AMBIGÜEDAD FP / TP

Ambos suman +1,40 por 6 meses sin pagar. El **plan de asistencia (+0,46)** decide:

FP: z = −0,24 → 0,441 → 0 ✓
TP: z = +0,06 → 0,516 → 1 ✓

FN: los pagos regulares compensan el retraso → 0,320; solo se detecta con t = 0,25.

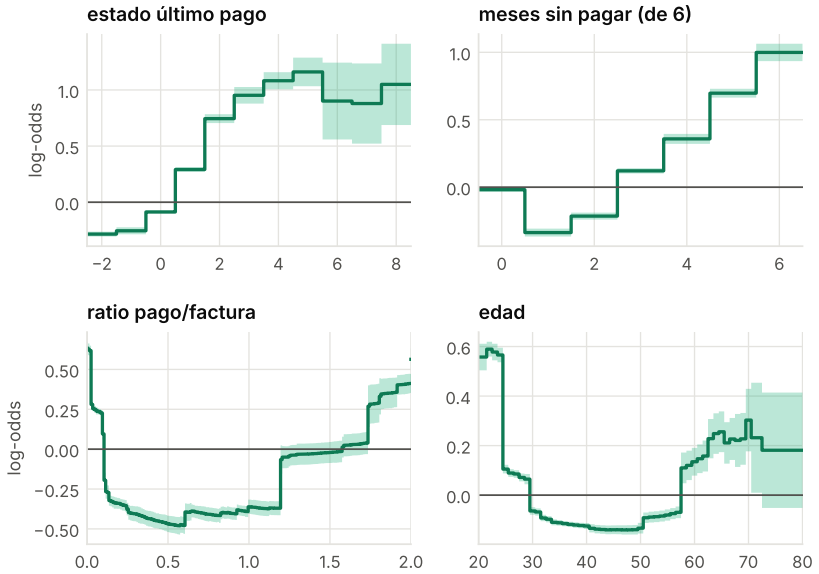
Ojo: el plan se asigna a quien ya tiene estrés financiero → **asociación, no causa**.

MODELO ADITIVO

EBM: el mejor modelo, con relaciones no monótonas que la RL no puede ver

ExplainableBoostingClassifier, interactions = 0 · ROC AUC 0,776 · una función de forma $f_j(x_j)$ por variable · **> 0 sube el riesgo**, **< 0 lo baja**

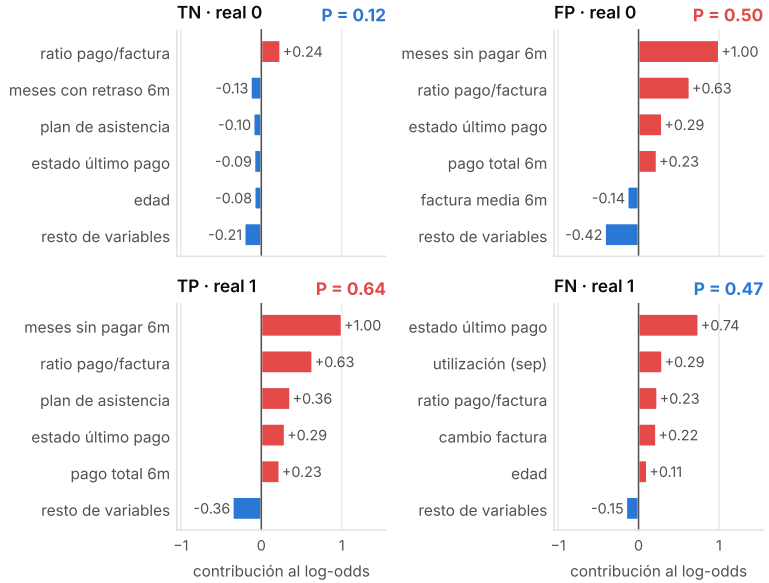
INTERPRETACIÓN GLOBAL · FUNCIONES DE FORMA



- **Estado último pago**: ≤ 0 resta riesgo; el 1.er mes de retraso salta a ≈ +0,30 y sube por escalones hasta ≈ +1,1 (4–5 meses).
- **Meses sin pagar**: no monótona; mínimo con 1 mes (≈ −0,33), ≥ 3 meses crece hasta ≈ +1,0.
- **Pago/factura**: forma de U; no pagar ≈ +0,62, mínimo ≈ −0,45 entre 0,4 y 0,6, sube a ≈ +0,4 por encima de 1,75 → por eso la RL le da coef. ≈ 0.
- **Edad**: U; < 25 años ≈ +0,6, mínimo 30–50, vuelve a subir desde 57. La RL solo recoge el primer tramo.

Banda = incertidumbre entre bolsas de entrenamiento.

INTERPRETACIÓN LOCAL · CONTRIBUCIONES DEL EBM

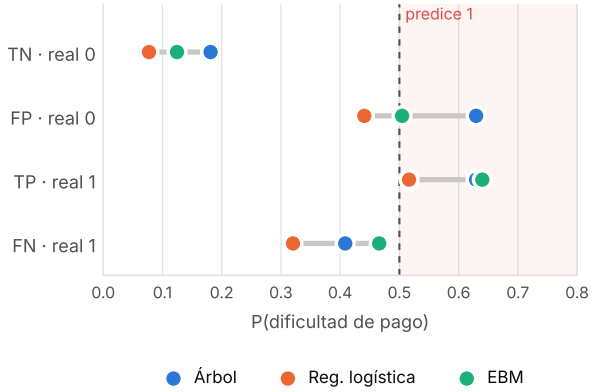


TP (0,640) supera a FP (0,505) en 13,5 puntos por el plan de asistencia (+0,36 frente a −0,10), aunque FP sigue siendo alarma. FN sube a 0,466, la más alta de los tres modelos, por estado de pago 2 (+0,74) y utilización 99 % (+0,29).

DISCUSIÓN

- El EBM ofrece el mejor compromiso: aditivo como la RL, pero una curva por variable.
- Ningún modelo resuelve las cuentas inactivas → un indicador de cuenta inactiva mejoraría FP/TP.
- Mejoras: categóricas sin codificar, ajustar hiperparámetros del EBM y umbral con función de costes.

LOS 3 MODELOS, MISMOS CASOS



Coinciden en TN; discrepan en FP (solo la RL acierta). Ninguno detecta FN con 0,5; los tres con 0,25.